

PPO 기반 RLHF 미세조정에서 KL 계수가 보상-다양성 트레이드오프에 미치는 영향: KoChatGPT 사례 연구

Yongseok Oh
ysoh1113@gmail.com

Abstract—RLHF(Reinforcement Learning from Human Feedback)의 마지막 단계인 PPO 미세조정은 보상 극대화과 원래 정책으로부터의 이탈을 억제하는 KL 페널티 사이의 트레이드오프로 정의된다. 이 트레이드오프를 통제하는 KL 계수 β 는 널리 쓰이는 한국어 RLHF 튜토리얼 프로젝트인 KoChatGPT(airobotlab, 2023; ColossalAI Coati 기반)에서 검증 없이 라이브러리 기본값(0.1)으로 고정되어 있었다. 본 연구는 $\beta \in \{0, 0.02, 0.05, 0.1, 0.3, 1.0\}$ 에 대한 통제된 스왑 실험과, 그중 세 조건 ($\beta=0, 0.02, 0.1$)에 대한 2개 추가 시드 반복 실험을 수행하여, KoGPT2 기반 RLHF-PPO 미세조정에서 β 가 보상, 실제 KL divergence, 생성 다양성에 미치는 영향을 정량화한다. 실험 결과 (i) 본 실험 규모(조건당 1-3개 시드, 10 episode)에서는 PPO로 미세조정된 6개 조건 모두 SFT baseline보다 평균 보상이 낮았고, (ii) 샘플 단위 반복률(repetition rate) 지표로 보면 baseline을 포함한 거의 모든 조건에서 반복 붕괴 경향이 관측되어 이 경향이 β 가 아니라 SFT 단계에서부터 이어진 것으로 보이며, (iii) 시드 반복 실험에서 동일 시드 내 β 간 차이가 시드 간 차이보다 작아, 이 규모에서는 β 의 효과가 시드 분산에 의해 가려질 수 있음을 확인했다. 또한 (iv) corpus 단위로 풀링된 distinct-n 지표가 실제로는 반복 붕괴가 있는 조건을 "다양성이 충분하다"고 잘못 판정하는 사례를 정량적으로 확인하여, 샘플 단위 반복률 지표를 보완 기준으로 제안한다.

I. INTRODUCTION

RLHF는 (i) supervised fine-tuning(SFT), (ii) 보상모델(RM) 학습, (iii) PPO 기반 정책 미세조정의 3단계로 구성된다. 이 마지막 단계에서 정책은 보상모델의 점수를 최대화하는 동시에, 원래 정책(SFT)으로부터 지나치게 벗어나지 않도록 KL divergence로 정규화된다. 이 정규화의 강도를 결정하는 계수 β 는 RLHF의 핵심 하이퍼파라미터임에도 불구하고, 실습/튜토리얼 목적의 오픈소스 구현체에서는 검증 없이 기본값이 그대로 쓰이는 경우가 많다.

본 연구는 ColossalAI Coati 라이브러리를 이용해 KoGPT2로 RLHF 파이프라인을 재현하는 한국어 튜토리얼 프로젝트 KoChatGPT [1], [2]를 확장 대상으로 삼는다. 실제 라이브러리 소스 코드를 분석한 결과, PPOTrainer의 KL 계수 인자(kl_coef)는 기본값 0.1로 설정되어 있고, KoChatGPT 튜토리얼은 이 값을 한 번도 검증하지 않은 채 그대로 사용하고 있었다. 본 연구는 바로 이 지점 - β 가 실제로 결과에 미치는 영향 - 을 체계적인 스왑 실험과 다중 시드 반복 실험으로 검증함으로써 기존 연구를 확장한다.

A. 연구 질문 및 가설

- **H1.** β 가 작을수록 보상모델 점수는 높아지지만, 생성 다양성은 낮아진다 (reward-diversity trade-off).
- **H2.** β 가 클수록 정책이 SFT 모델에서 거의 벗어나지 못해 보상 개선이 미미하다.

- **H3.** 두 극단 사이에 보상 개선 대비 텍스트 붕괴가 적은 중간 지점이 존재한다.

B. 기여

- KoChatGPT의 PPO 단계에서 미검증 상태였던 KL 계수 β 를 체계적으로 스왑하고, 이를 실제 라이브러리 소스 (보상 계산식, KL 추정 방식)에 기반해 재현 가능한 형태로 구현하였다.
- Corpus 단위로 풀링된 distinct-n과 별도로, 샘플 단위 반복률 (repetition rate) 및 이를 이용한 퇴화(degenerate) 판정 지표를 정의하여 모델 선택 기준에 통합하고, 이 지표가 corpus 단위 지표만으로는 드러나지 않는 반복 붕괴 사례를 실제로 탐지함을 정량적으로 보였다.
- 세 가지 β 값에 대해 추가 시드 2개로 반복 실험을 수행하여, 관측된 β 간 차이가 시드 분산 대비 얼마나 큰지를 정량적으로 비교하였다.

II. BACKGROUND

A. PPO 기반 RLHF

SFT로 얻은 초기 정책 π_{SFT} 를 보상모델 $r_\phi(x, y)$ 로 미세조정할 때, KL 정규화가 포함된 보상은 다음과 같이 정의된다 [3], [4]:

$$R(x, y) = r_\phi(x, y) - \beta \cdot D_{\text{KL}}(\pi_\theta(\cdot | x) \| \pi_{\text{SFT}}(\cdot | x)) \quad (1)$$

정책 π_θ 는 PPO의 클리핑된 목적함수로 학습된다 [5]:

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min \left(\rho_t(\theta) \hat{A}_t, \text{clip}(\rho_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right] \quad (2)$$

여기서 $\rho_t(\theta) = \pi_\theta(a_t | s_t) / \pi_{\theta_{\text{old}}}(a_t | s_t)$ 이고, $\hat{A}_t$ 는 GAE 기반 advantage 추정값이다.

III. RELATED WORK

Base system. 본 연구가 확장하는 KoChatGPT [1]는 ColossalAI의 Coati(applications/Chat) [2] 라이브러리를 이용해 KoGPT2 기반 SFT-RM-PPO 파이프라인을 재현하는 한국어 튜토리얼이다.

KL-regularized RLHF. 식 (1)의 목적함수는 Ziegler et al. [3]이 처음 제안했고, Stiennon et al. [6]은 reward-KL frontier를 결과 제시의 표준 형식으로 정착시켰으며, Ouyang et al. (InstructGPT) [4]이 대규모 상용 시스템에 적용하였다. 본 연구의 실험 설계(그리드 스왑, reward-KL frontier plot)

는 이 계보를 직접 따르되, 소규모 재현 환경에서 다중 시드 반복까지 포함하여 결과의 신뢰 구간을 함께 보고한다.

Reward overoptimization. Gao et al. [7]은 보상모델을 과도하게 최적화할 경우 실제 선호도와 무관하게 보상 점수만 높아지는 현상을 대규모 스케일링 법칙으로 분석하였다. 본 연구에서 사용한 보상모델은 순위 데이터의 일부만으로 학습되어 상대적으로 노이즈가 클 가능성이 있으며, 이는 §VII에서 논의하는 결과 해석에 관련된다.

다양성 지표의 한계. Distinct-n 지표는 Li et al. [8]이 제안했으며, Holtzman et al. [9]은 corpus 단위로 집계된 지표가 개별 샘플의 반복(degeneration)을 놓칠 수 있음을 지적하였다. 본 연구는 이 한계를 실제 실험에서 수치로 확인하였다 (§VII).

IV. METHOD

A. Base System

Actor는 SFT 체크포인트, critic과 reward model은 RM 체크포인트로 초기화되며, initial model은 SFT 정책을 그대로 고정(freeze)한 참조 정책이다. PPOTrainer의 기본 하이퍼파라미터는 $kl_coef=0.1$, $eps_clip=0.2$, $value_clip=0.4$ 이다. 보상모델은 KoChatGPT 튜토리얼의 순위 데이터 중 10%(total_using_ratio=0.1) 만으로 학습되었다.

B. 제안하는 확장: KL 계수 스윙

β 가 보상-다양성 트레이드오프에 미치는 영향을 정량화하기 위해 그리드 $\mathcal{B} = \{0, 0.02, 0.05, 0.1, 0.3, 1.0\}$ 에 대해 PPO 미세조정을 독립적으로 수행한다($\beta=0.1$ 은 기존 튜토리얼의 미검증 기본값). β 를 제외한 모든 하이퍼파라미터와 초기 체크포인트는 고정하여 관측되는 차이가 β 만의 효과가 되도록 통제한다. 조건 간 공정한 비교를 위해 매 β 마다 actor/critic/initial model을 SFT/RM 체크포인트에서 새로 초기화한다.

C. 시드 반복 실험

단일 시드 스윙만으로는 조건 간 차이가 β 의 체계적 효과인지, 아니면 학습 과정의 확률적 변동(rollout 샘플링, 파라미터 초기화 등)에 의한 노이즈인지 구분하기 어렵다. 이를 확인하기 위해 $\beta \in \{0, 0.02, 0.1\}$ 세 조건에 대해 서로 다른 난수 시드 2개(seed $\in \{1, 2\}$)로 학습을 반복하고, 원래 스윙의 결과(seed=0격)와 합쳐 조건당 3회 관측으로 평균과 표준편차를 계산한다.

D. 평가 프로토콜

학습에 사용되지 않은 held-out 프롬프트 $N=30$ 개에 대해 greedy decoding으로 생성한 뒤 다음을 측정한다.

- **Reward score:** r_ϕ 가 매긴 점수의 평균/표준편차.
- **Actual KL:** Schulman의 편향이 적은 k3 추정치 [5]를 사용한다.

$$\hat{D}_{KL} = \mathbb{E}[(e^\Delta - 1) - \Delta], \quad \Delta = \log \pi_\theta(a | s) - \log \pi_{SFT}(a | s) \quad (3)$$

- **Distinct-n** [8]: 생성문 전체(30개 held-out 응답 전체)를 풀링해 계산한 유니크 n-gram 비율.

$$\text{distinct-}n = \frac{|\{\text{unique } n\text{-grams}\}|}{|\{\text{total } n\text{-grams}\}|} \quad (4)$$

- **샘플 단위 반복률(repetition rate):** 개별 응답 y 내부의 반복 정도를 측정하여 corpus 단위 distinct-n이 놓칠 수 있는 단일 샘플의 붕괴를 포착한다.

$$\text{rep}(y) = 1 - \frac{|\{\text{unique bigrams in } y\}|}{|\{\text{total bigrams in } y\}|} \quad (5)$$

생성된 부분만(프롬프트 제외, action mask 기준) 디코딩하여 계산한다.

- **퇴화(degenerate) 판정:** 응답 y 가 반복률 임계값을 넘거나 생성 토큰 수가 지나치게 적으면(사실상 공백) 퇴화로 표시한다.

$$\text{is_degenerate}(y) = \mathbb{I}[\text{rep}(y) > \tau_{\text{rep}} \vee |y| < \tau_{\text{len}}] \quad (6)$$

한 조건의 30개 평가 응답 중 하나라도 퇴화로 표시되면 그 조건 전체를 any_degenerate=True로 표시한다.

E. 모델 선택 기준

학습 전(SFT) 대비 distinct-2가 70% 이상 유지되고, any_degenerate가 False인 조건들 중 reward score가 가장 높은 조건을 최적 모델로 선택한다.

$$\beta^* = \underset{\beta \in \mathcal{B}'}{\operatorname{argmax}} \bar{r}_\phi(\beta), \quad \mathcal{B}' = \{\beta \in \mathcal{B} : \text{distinct2}(\beta) \geq 0.7 \times \text{distinct2}_{SFT} \wedge \text{any_degenerate} = \text{False}\} \quad (7)$$

$\mathcal{B}'$ 가 공집합이면 β^* 는 정의되지 않은 것으로 보고한다 (§VI 참고).

V. EXPERIMENTAL SETUP

TABLE I: 고정 하이퍼파라미터

항목	값
Base model	KoGPT2 (skt/kogpt2-base-v2)
PPO 데이터	kochatgpt_3_PPO.jsonl
RM 학습 데이터 비율	10% (total_using_ratio=0.1)
β 그리드	{0, 0.02, 0.05, 0.1, 0.3, 1.0}
시드 반복 대상 β	{0, 0.02, 0.1} (추가 시드 2개)
max_epochs	1
train_batch_size	8
num_episodes	10
max_timesteps	3
update_timesteps	3
eps_clip	0.2
value_clip	0.4
평가 프롬프트 수	30 (held-out)
평가 디코딩	greedy
학습 디코딩	sampling (top-k=50, T=1.0)

VI. RESULTS

TABLE II: β 스윙 결과 (조건당 단일 시드, $N=30$)

β	Reward	KL	D-1	D-2	max rep
baseline (SFT)	2.545	0.000	0.683	0.762	0.950
0.00	1.815	0.258	0.407	0.521	0.952
0.02	1.992	0.129	0.608	0.734	0.794
0.05	1.780	0.115	0.652	0.764	0.950
0.10	2.194	0.164	0.449	0.531	0.942
0.30	2.136	0.291	0.494	0.608	0.950
1.00	1.589	0.109	0.495	0.634	0.800

7개 조건 모두 `any_degenerate=True`로 판정되어(즉 30개 평가 응답 중 최소 하나 이상이 식 (6)의 퇴화 기준을 만족), 식 (7)의 B' 는 공집합이고 β^* 는 정의되지 않는다(`best_kl_coef=None`). 6개 PPO 조건 모두 보상 평균이 SFT baseline(2.545)보다 낮다.




Fig. 1: 6개 조건의 reward-KL frontier(좌)와 β 에 따른 distinct-2(우). 연결선 없이 점으로만 표시하여, 실제 KL이 β 순서에 대해 단조적이지 않음을 있는 그대로 나타냈다.

TABLE III: 시드 반복 실험: 3개 시드 평균 $\pm$ 표준편차 ($\beta \in \{0, 0.02, 0.1\}$)

β	Reward	KL	Distinct-2
0.00	2.038 ± 0.240	0.326 ± 0.082	0.624 ± 0.094
0.02	2.102 ± 0.179	0.284 ± 0.145	0.695 ± 0.045
0.10	2.196 ± 0.181	0.298 ± 0.120	0.631 ± 0.088




Fig. 2: $\beta \in \{0, 0.02, 0.1\}$ 에 대한 reward-KL frontier(평균 $\pm$ 표준편차, $n=3$ 시드). 오차 막대가 조건 간 평균 차이보다 크거나 비슷해, 이 규모에서는 β 의 효과가 시드 분산과 뚜렷이 구분되지 않음을 보여준다.

표 III와 그림 2에서 β 간 평균 reward 차이는 최대 0.16 ($\beta=0.00$ 대 $\beta=0.10$)인 반면, 각 β 내 시드 간 표준편차는 0.18–0.24로 그보다 크거나 비슷하다. 즉 이 실험 규모에서는 β 를 바꿔서 얻는 평균적 차이가 같은 β 를 다른 시드로 재현했을 때 생기는 차이보다 작다.

VII. DISCUSSION

A. PPO 미세조정이 baseline 보상을 넘지 못함

표 II에서 보듯 6개 PPO 조건 모두 SFT baseline(2.545)보다 낮은 평균 보상(1.59–2.19)을 보였다. 이는 (i) 보상모델이

순위 데이터의 10%만으로 학습되어 일반화 성능이 제한적이었을 가능성과, (ii) 10-episode 라는 극소 학습 예산이 안정적인 정책 개선에 애초에 불충분했을 가능성을 함께 시사한다. 이 결과는 β 값과 무관하게 나타나므로, β 자체의 효과라기보다 실험 규모의 한계로 해석하는 것이 합리적이다.

B. 반복 붕괴는 β 가 아니라 SFT 단계에서 이어짐

baseline(PPO 학습 전 SFT 모델) 자체가 이미 `max_repetition=0.950`으로 심한 반복 경향을 보인다. PPO로 학습한 6개 조건의 `max_repetition`도 0.794–0.952로 baseline과 비슷한 범위에 머물러 있어, 관측된 반복 붕괴가 PPO나 β 가 새로 유발한 문제라기보다 KoGPT2(125M)를 소량의 데이터로 SFT한 데서 이미 존재 하던 경향을 PPO가 그대로 물려받은 것으로 해석된다. 다만 6개 조건 중 $\beta=0.02$ (0.794)와 $\beta=1.00$ (0.800)이 상대적으로 가장 낮은 `max_repetition`을 보여, β 가 아주 작거나 아주 클 때 오히려 반복이 다소 완화되는 경향이 약하게 관측된다.

C. β 의 효과는 시드 분산 규모 내에 있음

§IV-C의 시드 반복 실험(표 III)은 이 해석을 뒷받침한다. 동일 시드 내에서 $\beta=0, 0.02, 0.1$ 을 바꿔도 reward, KL, distinct-2가 거의 변하지 않는 반면(예: seed 2에서 $\beta=0.00$ 과 $\beta=0.02$ 의 reward는 소수점 자리까지 동일했다), 시드를 바꾸면 그보다 큰 차이가 발생했다. 이는 조건당 단일 시드로 얻은 reward-KL frontier가 대규모 연구에서 보고된 매끈한 곡선 [3], [6]과 다르게 나타날 수 있음을 설명하며, KL 정규화의 이론적 효과가 신뢰성 있게 관측되려면 조건당 다중 시드와 더 큰 학습 예산이 필요함을 시사한다.

D. Corpus 단위 distinct-n의 사각지대

$\beta=0.05$ 는 distinct-2가 0.764로 baseline(0.762)과 사실상 같거나 오히려 높아, 식 (7)의 다양성 하한선($0.7 \times 0.762 = 0.533$)을 여유 있게 통과한다. 그러나 `max_repetition`은 baseline과 동일한 0.950으로, 30개 평가 응답 중 적어도 하나는 여전히 심하게 반복되는 퇴화 응답임을 의미한다. 즉 corpus 전체를 폴링한 distinct-2만 보면 이 조건은 “다양성이 충분하다”고 잘못 판정되지만, 샘플 단위 반복률(식 (5))과 퇴화 판정(식 (6))을 함께 보면 실제로는 후보에서 제외되어야 함이 드러난다. 이는 Holtzman et al. [9]이 지적한 corpus 단위 다양성 지표의 한계를 본 실험에서 수치로 확인한 사례이며, Gao et al. [7]이 논의하는 것처럼 제한된 데이터로 학습된 보상모델·다양성 지표만으로 모델을 선택하는 것의 위험성을 뒷받침한다.

VIII. LIMITATIONS

본 연구는 다음과 같은 한계를 가진다: (i) 주 스왑(6개 조건)은 조건당 단일 시드로만 수행되었고, 시드 반복은 $\beta \in \{0, 0.02, 0.1\}$ 세 조건(추가 시드 2개, 총 3회 관측)에 대해서만 수행되었다, (ii) 학습 예산이 극히 작아 (10 episode) β 의 장기적 효과를 완전히 관측하지 못했을 수 있다, (iii) 보상모델이 순위 데이터의 10%만으로 학습되어 보상 신호 자체의 신뢰도가 제한적일 수 있다, (iv) 125M 파라미터의 소형 모델(KoGPT2)을 사용하여 대규모 모델에서의 일반화 가능성은 별도 검증이 필요하다, (v) 평가 프롬프트가 30개로 제한적이다.

IX. CONCLUSION AND FUTURE WORK

본 연구는 KoChatGPT PPO 튜토리얼에서 검증되지 않았던 KL 계수 β 를 6개 조건에 대해 스윙하고, 그중 3개 조건을 추가 시드로 반복하여 검증하였다. 그 결과 (i) 본 실험 규모에서는 PPO로 학습한 모든 조건이 SFT baseline보다 낮은 보상을 보였고, (ii) 샘플 단위 반복 붕괴는 β 가 아니라 SFT 단계에서부터 이어지는 경향으로 보이며, (iii) 시드 반복 실험에서 β 간 차이가 시드 간 차이보다 작아 이 규모에서는 β 의 효과가 시드 분산에 가려질 수 있음을, (iv) corpus 단위 distinct-n이 실제로 존재하는 샘플 단위 반복 붕괴를 놓치는 구체적 사례를 확인하였다. 향후 연구로는 (1) 6개 조건 전체에 대한 다중 시드 반복을 통한 통계적으로 유의한 reward-KL frontier 재현, (2) 보상모델 학습에 사용하는 순위 데이터 비율 확대, (3) Ziegler et al. [3]이 제안한 adaptive KL controller의 적용, (4) 더 큰 모델과 학습 예산에서의 재현을 제안한다.

REFERENCES

- [1] airobotlab, “Kochatgpt: Chatgpt의 rlhf를 학습을 위한 3가지 step별 한국어 데이터셋,” <https://github.com/airobotlab/KoChatGPT>, 2023.
- [2] HPC-AI Tech, “Colossalchat: An open-source solution for cloning chatgpt with a complete rlhf pipeline,” <https://github.com/hpcaitech/ColossalAI/tree/main/applications/Chat>, 2023.
- [3] D. M. Ziegler, N. Stiennon, J. Wu, T. B. Brown, A. Radford, D. Amodei, P. Christiano, and G. Irving, “Fine-tuning language models from human preferences,” *arXiv preprint arXiv:1909.08593*, 2019.
- [4] L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray *et al.*, “Training language models to follow instructions with human feedback,” *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 35, 2022.
- [5] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, “Proximal policy optimization algorithms,” *arXiv preprint arXiv:1707.06347*, 2017.
- [6] N. Stiennon, L. Ouyang, J. Wu, D. M. Ziegler, R. Lowe, C. Voss, A. Radford, D. Amodei, and P. Christiano, “Learning to summarize from human feedback,” *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, 2020.
- [7] L. Gao, J. Schulman, and J. Hilton, “Scaling laws for reward model overoptimization,” in *International Conference on Machine Learning (ICML)*, 2023.
- [8] J. Li, M. Galley, C. Brockett, J. Gao, and B. Dolan, “A diversity-promoting objective function for neural conversation models,” in *Proceedings of NAACL-HLT*, 2016.
- [9] A. Holtzman, J. Buys, L. Du, M. Forbes, and Y. Choi, “The curious case of neural text degeneration,” in *International Conference on Learning Representations (ICLR)*, 2020.